



Algoritmik Adalette Doğruluğun Bedeli:

**Adult Census Income Veri Seti Üzerinde
Karşılaştırmalı Bir Analiz**

Makine Öğrenmesi

Makine öğrenmesi dersi dönem proje rapouru

Alperen ALAÇERİ
250708029@samsun.edu.tr

Etik İkelere Uygunluk Beyanı

Dönem proje yazma sürecinde bilimsel ve etik ilkelere uyduğumu, yararlandığım tüm kaynakları kaynak gösterme ilkelerine uygun olarak kaynakçada belirttiğimi ve bu bölümler dışındaki tüm ifadelerin şahsıma ait olduğunu beyan ederim.

İmza
Alperen Alaçeri

Algoritmik Adalette Doğruluğun Bedeli: Adult Census Income Veri Seti Üzerinde Karşılaştırmalı Bir Analiz

Alperen ALAÇERİ

SAMSUN ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ
2026

ÖZET

Bu çalışma, **Adult Census Income** veri seti üzerinde makine öğrenmesi modellerinin tahminsel başarımı ile cinsiyet temelli adalet metrikleri arasındaki etkileşimi nicel olarak incelemektedir. Araştırma kapsamında Lojistik Regresyon ve Karar Ağaçları gibi yorumlanabilir modellerin yanı sıra, **Random Forest** ve **XGBoost** gibi yüksek performanslı topluluk modelleri (**ensemble models**) analiz edilmiştir. Algoritmik yanlılığın (**algorithmic bias**) tespiti ve azaltılması süreci, literatürde kabul görmüş **Statistical Parity Difference (SPD)** ve **Equal Opportunity Difference (EOD)** metrikleri üzerinden yürütülmüştür (Chouldechova, 2017; Hardt et al., 2016).

Deneyisel sonuçlar, modellerin doğruluğu (**accuracy**) ile grup adaleti arasında ters yönlü bir ilişki olduğunu, yani kaçınılmaz bir **doğruluk-adalet ödünleşimi (accuracy-fairness trade-off)** bulunduğunu doğrulamaktadır (Plečko & Bareinboim, 2024). Özellikle **XGBoost** modelinin en yüksek ROC-AUC skoruna ulaşmasına rağmen en yüksek cinsiyet yanlılığını sergilediği, bu karmaşıklığın yanlılığı bazen örtük hale getirdiği görülmüştür (Gohar et al., 2023). **Exponentiated Gradient (ExpGrad)** gibi müdahale yöntemlerinin uygulanması sonucunda adalet metriklerinde iyileşme sağlanmış, ancak bu durum bir **müdahale maliyeti (intervention cost)** olarak genel doğruluk oranlarında düşüşe neden olmuştur (Plečko & Bareinboim, 2024). Bu çalışma, **Sorumlu Yapay Zeka (Responsible AI)** çerçevesinde, karar destek sistemlerinde adalet ve performans arasında Pareto-optimal bir dengenin kurulması gerektiğini savunmaktadır. Ayrıca gerçekleştirilen 5-Fold Stratified Cross Validation sonuçları, elde edilen bulguların farklı veri bölünmelerinde de kararlı olduğunu göstermiştir.

Anahtar Kelimeler: Makine Öğrenmesi, Algoritmik Adalet (Algorithmic Fairness), Adult Census Veri Seti, Cinsiyet Yanlılığı (Gender Bias), Sorumlu Yapay Zeka (Responsible AI), Doğruluk-Adalet Ödünleşim Analizi (Accuracy-Fairness Trade-off).

The Price of Fairness in Algorithmic Decision-Making: A Comparative Analysis on the Adult Census Income Dataset

Alperen ALAÇERİ

**SAMSUN UNIVERSITY
FACULTY OF ENGINEERING AND NATURAL SCIENCES
DEPARTMENT OF SOFTWARE ENGINEERING
2026**

ABSTRACT

This study quantitatively examines the interaction between the predictive performance of machine learning models and gender-based fairness metrics using the Adult Census Income dataset. Logistic Regression and Decision Tree models, as well as high-performance ensemble models such as Random Forest and XGBoost, were analyzed. The process of detecting and mitigating algorithmic bias was conducted through widely recognized metrics: Statistical Parity Difference (SPD) and Equal Opportunity Difference (EOD) (Chouldechova, 2017; Hardt et al., 2016).

Experimental results confirm an inverse relationship between model accuracy and group fairness, establishing an inevitable accuracy-fairness trade-off (Plečko & Bareinboim, 2024). Specifically, it was observed that ensemble models reached the highest ROC-AUC scores but exhibited significant gender bias, suggesting that model complexity can amplify or mask existing disparities (Gohar et al., 2023). The application of mitigation methods like Exponentiated Gradient (ExpGrad) improved fairness metrics; however, this resulted in a decrease in overall accuracy, interpreted as an intervention cost (Plečko & Bareinboim, 2024). This study argues for the necessity of establishing a Pareto-optimal balance between fairness and performance in decision-making systems within the framework of Responsible AI. Furthermore, the 5-Fold Stratified Cross Validation analysis confirmed that the observed performance and fairness outcomes were stable across different data splits, indicating that the reported findings were not dependent on a specific train-test partition.

Keywords: Machine Learning, Algorithmic Fairness, Adult Census Dataset, Gender Bias, Responsible AI, Accuracy-Fairness Trade-off, Bias Mitigation.

İçindekiler

Etik İlkeler Uyumluk Beyanı	I
Şekiller Listesi	VI
Tablolar Listesi	VII
1. Giriş	8
1.1. Problem Tanımı ve Motivasyon	9
1.2. Araştırmanın Amacı ve Katkıları	11
1.3. Araştırma Soruları ve Hipotezler	12
2. KAVRAMSAL ÇERÇEVE	14
2.1 Algoritmik Yanlılık ve Algoritmik Adalet	14
2.2 Adalet Değerlendirme Metrikleri	15
2.2.1 Statistical Parity Difference (SPD)	15
2.2.2 Equal Opportunity Difference (EOD)	15
2.2.3 Disparate Impact (DI)	16
2.3 Doğruluk–Adalet Ödünleşimi (Accuracy–Fairness Trade-Off)	16
3. MATERYAL VE YÖNTEM	17
3.1 Veri Seti	17
3.2 Veri Ön İşleme Süreci	18
3.3 Kullanılan Makine Öğrenmesi Modelleri	18
3.3.1 Logistic Regression	18
3.3.2 Decision Tree	19
3.3.3 Random Forest	19
3.3.4 XGBoost	19
3.4 Deneysel Tasarım	19
Baseline Deneyi	19
No-Sex Deneyi	19
No-Demographic Deneyi	19
Reweighting Deneyi	19
Exponentiated Gradient Deneyi	19
3.5 Değerlendirme Metrikleri	19
4. BULGULAR VE DEĞERLENDİRME	20
4.1 Baseline Model Sonuçları	20
4.1.1 K-Fold Çapraz Doğrulama Sonuçları	21
4.2 Korunan Özniteliklerin Kaldırılmasının Etkisi	21
4.3 Fairness Müdahalelerinin Etkisi	22

4.4 Doğruluk–Adalet Ödünleşimi Analizi.....	23
5.TARTIŞMA.	25
5.1. Korunan Özniteliklerin Kaldırılmasının Etkisi.....	25
5.2. Fairness Müdahalelerinin Karşılaştırılması.....	25
5.3. Doğruluk–Adalet Ödünleşimi	26
5.4. Çalışmanın Kısıtları	27
6.SONUÇ VE ÖNERİLER.....	27
6.1. Çalışmanın Temel Sonuçları.....	27
6.2. Gelecek Çalışmalar	29
KAYNAKÇA	30

Şekiller Listesi

Şekil 1 Veri İşleme ve Deney Akışı	18
Şekil 2 Accuracy–SPD Doğruluk–Adalet Ödünleşimi Grafiği.....	24

Tablolar Listesi

Tablo 1 Veri Seti Özeti	17
Tablo 2 Baseline Modellerin Sonuçları	20
Tablo 3 XGBoost K-Fold Çapraz Doğrulama Sonuçları.....	21
Tablo 4 No-Sex Deneyi Sonuçları.....	21
Tablo 5 No-Demographic Deneyi Sonuçları.....	22
Tablo 6 Reweighing Sonuçları	22
Tablo 7 K-Fold Fairness Sonuçları.....	23
Tablo 8 Exponentiated Gradient Sonuçları	23

1. Giriş

Makine öğrenmesi algoritmaları günümüzde finans, istihdam, sağlık, eğitim ve kamu hizmetleri gibi birçok alanda karar destek sistemlerinin temel bileşeni haline gelmiştir. Bu sistemler büyük veri kümeleri üzerinden örüntü öğrenerek yüksek tahmin başarımı sağlayabilmekte; ancak eğitim verilerinde bulunan tarihsel eşitsizlikleri, temsil dengesizliklerini ve toplumsal önyargıları da öğrenme riski taşımaktadır. Bu durum, özellikle cinsiyet, ırk, yaş veya sosyo-ekonomik durum gibi korunan ya da hassas özellikler açısından belirli gruplar lehine veya aleyhine sistematik sonuçlar üreten algoritmik yanlılık problemini ortaya çıkarmaktadır (Hort et al., 2024; Mehrabi et al., 2021).

Algoritmik yanlılık problemi, yalnızca modelin hatalı tahmin üretmesiyle sınırlı değildir. Bir model genel doğruluk açısından başarılı görünse bile, farklı demografik gruplar üzerinde eşit olmayan karar oranları veya hata oranları üretebilir. Bu nedenle Sorumlu Yapay Zeka yaklaşımı, modellerin yalnızca accuracy, F1-score veya ROC-AUC gibi performans metrikleriyle değil, aynı zamanda Statistical Parity Difference (SPD), Equal Opportunity Difference (EOD) ve Disparate Impact (DI) gibi adalet metrikleriyle de değerlendirilmesini gerekli görmektedir (Chouldechova, 2017; Hardt et al., 2016).

Bu çalışmada Adult Census Income veri seti kullanılarak bireylerin yıllık gelir düzeyinin 50.000 doların üzerinde olup olmadığını tahmin eden makine öğrenmesi modelleri incelenmiştir. Adult veri seti, algoritmik adalet literatüründe yaygın biçimde kullanılan klasik veri setlerinden biridir; ancak 1994 yılı ABD nüfus sayımı verilerine dayanması, gelir eşliğinin tarihsel bağlama bağlı olması ve demografik gruplar arasında dengesizlikler içermesi nedeniyle adalet çalışmaları açısından hem önemli hem de tartışmalı bir benchmark olarak değerlendirilmektedir (Barredo Arrieta et al., 2020; Ding et al., 2021).

Araştırma kapsamında Logistic Regression, Decision Tree, Random Forest ve XGBoost modelleri eğitilmiş; bu modellerin tahmin performansları ile cinsiyet temelli adalet metrikleri karşılaştırılmıştır. Bunun yanında, yalnızca yüksek doğruluk elde etmeye odaklanan modellerin grup adaleti açısından ne ölçüde sorun üretebildiği incelenmiş ve doğruluk-adalet ödünleşimi Accuracy–SPD trade-off analizi ile değerlendirilmiştir.

Çalışmanın ayırt edici yönlerinden biri, yalnızca fairness-aware yöntemlerin etkisini incelemekle sınırlı kalmaması, aynı zamanda korunan özniteliğin veri setinden çıkarılmasının adalet üzerindeki etkisini de deneysel olarak test etmesidir. Bu amaçla No-Sex deneyinde cinsiyet değişkeni veri setinden çıkarılmış; No-Demographic deneyinde ise sex, race, native-country, marital-status ve relationship gibi demografik veya demografik özelliklerle güçlü ilişkili değişkenler kaldırılmıştır. Böylece “korunan değişkeni kaldırmak adalet için yeterli midir?” sorusu deneysel olarak değerlendirilmiştir.

Elde edilen bulgular, cinsiyet değişkeninin veya bazı demografik değişkenlerin veri setinden çıkarılmasının adalet metriklerinde anlamlı bir iyileşme sağlamadığını göstermektedir. Bu durum, modellerin doğrudan korunan öznitelikleri kullanmasa bile occupation, education, hours-per-week veya capital-gain gibi vekil değişkenler üzerinden benzer örüntüleri öğrenebildiğini göstermektedir. Bu nedenle algoritmik adaletin yalnızca hassas değişkenlerin kaldırılmasıyla sağlanamayacağı, daha sistematik adalet müdahalelerine ihtiyaç duyulduğu sonucuna ulaşılmıştır.

Bu doğrultuda çalışmada Reweighing ve Exponentiated Gradient yöntemleri uygulanmış ve bu yöntemlerin model performansı ile adalet metrikleri üzerindeki etkileri karşılaştırılmıştır. Reweighing yöntemi doğruluk kaybını sınırlı tutarak adalet metriklerinde iyileşme sağlarken, Exponentiated Gradient yöntemi daha güçlü adalet iyileşmesi üretmiş ancak belirli ölçüde performans kaybına neden olmuştur. Bu sonuçlar, literatürde tartışılan accuracy-fairness trade-off kavramını deneysel olarak desteklemektedir (Plečko & Bareinboim, 2024).

1.1. Problem Tanımı ve Motivasyon

Makine öğrenmesi sistemleri son yıllarda işe alım, kredi değerlendirme, sigorta risk analizi, eğitim planlaması ve sağlık hizmetleri gibi birçok kritik alanda yaygın olarak kullanılmaya başlanmıştır. Bu sistemlerin karar süreçlerine artan düzeyde entegre edilmesi, yalnızca performanslarının değil aynı zamanda ürettikleri kararların adil olup olmadığının da değerlendirilmesini gerekli hale getirmiştir.

Geleneksel makine öğrenmesi çalışmalarında modeller çoğunlukla doğruluk, kesinlik, duyarlılık ve ROC-AUC gibi performans ölçütleri üzerinden değerlendirilmektedir. Ancak yüksek performans değerleri elde edilmesi, modelin tüm bireyler veya gruplar için eşit derecede adil kararlar ürettiği anlamına gelmemektedir(Saha, 2025). Özellikle cinsiyet, ırk, yaş ve etnik köken gibi korunan özellikler söz konusu olduğunda, modeller belirli gruplar lehine veya aleyhine sistematik farklılıklar oluşturabilmektedir (Chouldechova, 2017).

Algoritmik yanlılığın azaltılmasına yönelik ilk yaklaşımlardan biri, korunan özniteliklerin veri setinden çıkarılmasıdır. Bu yaklaşım literatürde fairness through unawareness olarak adlandırılmaktadır. Temel varsayım, modelin cinsiyet veya ırk gibi hassas bilgileri görmediği durumda ayrımcı kararlar üretmeyeceği yönündedir. Ancak son yıllarda yapılan çalışmalar, korunan özniteliklerin kaldırılmasının tek başına yeterli olmadığını göstermektedir. Çünkü eğitim düzeyi, meslek, çalışma süresi, medeni durum ve gelir bilgileri gibi değişkenler korunan özniteliklerle yüksek korelasyona sahip olabilir ve model tarafından vekil değişken (proxy attribute) olarak kullanılabilir (Caton & Haas, 2024)

Bu problem özellikle Adult Census Income veri setinde belirgin şekilde gözlenmektedir. Veri setinde yer alan eğitim düzeyi, çalışma süresi, meslek ve sermaye kazancı gibi değişkenler gelir tahmininde güçlü belirleyiciler olmakla birlikte, aynı zamanda cinsiyet grupları arasında tarihsel ve sosyo-ekonomik farklılıkları da yansıtabilmektedir. Bu nedenle yüksek doğruluk elde eden bir model, istemeden de olsa belirli gruplar için daha avantajlı kararlar üretebilir.

Bu çalışmanın temel motivasyonu, doğruluk ve adalet arasındaki ilişkinin deneysel olarak incelenmesidir. Bu amaçla öncelikle farklı makine öğrenmesi modellerinin performans ve adalet sonuçları değerlendirilmiş, ardından korunan özniteliklerin veri setinden çıkarılmasının etkisi analiz edilmiştir. Son aşamada ise Reweighting ve Exponentiated Gradient gibi fairness-aware yöntemler uygulanarak doğruluk ve adalet arasındaki ödünleşim incelenmiştir.

Bu kapsamda çalışma aşağıdaki araştırma sorularına cevap aramaktadır:

Yüksek doğruluk sağlayan modeller aynı zamanda adil kararlar üretebilmekte midir?

Korunan özniteliklerin veri setinden çıkarılması algoritmik yanlılığı azaltmak için yeterli midir?

Fairness-aware yöntemler adalet metriklerinde ne ölçüde iyileşme sağlamaktadır?

Adalet kazanımı ile tahmin performansı arasındaki ödünleşim ne düzeydedir?

Bu sorulara verilecek cevapların, gerçek dünya uygulamalarında kullanılacak yapay zekâ sistemlerinin daha şeffaf, güvenilir ve sorumlu biçimde geliştirilmesine katkı sağlayacağı düşünülmektedir.

1.2. Araştırmanın Amacı ve Katkıları

Bu çalışmanın temel amacı, makine öğrenmesi modellerinde doğruluk ve adalet arasındaki ilişkiyi incelemek ve farklı adalet iyileştirme yöntemlerinin model performansı üzerindeki etkilerini değerlendirmektir. Bu amaç doğrultusunda Adult Census Income veri seti kullanılarak bireylerin yıllık gelir düzeyinin tahmin edilmesi problemi ele alınmış ve farklı makine öğrenmesi modelleri hem performans hem de adalet metrikleri açısından karşılaştırılmıştır.

Çalışmada yalnızca geleneksel performans ölçütleriyle değerlendirme yapılmamış, aynı zamanda grup temelli adalet metrikleri kullanılarak modellerin farklı demografik gruplar üzerindeki davranışları da analiz edilmiştir. Böylece yüksek doğruluk sağlayan modellerin aynı zamanda ne kadar adil kararlar üretebildiği araştırılmıştır.

Bu çalışmanın başlıca katkıları aşağıda özetlenmiştir:

Adult Census Income veri seti üzerinde Logistic Regression, Decision Tree, Random Forest ve XGBoost modellerinin performans ve adalet açısından kapsamlı karşılaştırması gerçekleştirilmiştir.

Modeller yalnızca Accuracy, Precision, Recall, F1-Score ve ROC-AUC metrikleri ile değil; Statistical Parity Difference (SPD), Equal Opportunity Difference (EOD) ve Disparate Impact (DI) gibi adalet metrikleri ile de değerlendirilmiştir.

Korunan özniteliğin kaldırılmasının adalet üzerindeki etkisini incelemek amacıyla No-Sex deneyi gerçekleştirilmiş ve cinsiyet değişkeninin veri setinden çıkarılmasının adalet metriklerinde anlamlı bir iyileşme sağlamadığı gösterilmiştir.

Demografik özelliklerin etkisini daha kapsamlı değerlendirmek amacıyla No-Demographic deneyi uygulanmış ve yalnızca hassas değişkenlerin çıkarılmasının algoritmik yanlılığı ortadan kaldırmak için yeterli olmadığı ortaya konulmuştur.

Veri ön işleme temelli Reweighting yöntemi ile öğrenme sürecine müdahale eden Exponentiated Gradient yöntemi karşılaştırılmış ve bu yöntemlerin doğruluk ve adalet üzerindeki etkileri analiz edilmiştir.

Doğruluk ve adalet arasındaki ilişki Accuracy–SPD trade-off analizi ile görselleştirilmiş ve farklı modellerin doğruluk-adalet dengeleri karşılaştırılmıştır.

Elde edilen sonuçlar fairness through unawareness yaklaşımının sınırlılıklarını deneysel olarak ortaya koymuş ve fairness-aware yöntemlerin grup temelli ayrımcılığı azaltmada daha etkili sonuçlar üretebildiğini göstermiştir.

Bu yönleriyle çalışma, algoritmik adalet literatüründe yaygın olarak kullanılan Adult Census Income veri seti üzerinde hem korunan öznitelik kaldırma stratejilerini hem de fairness-aware müdahaleleri birlikte değerlendiren kapsamlı bir deneysel analiz sunmaktadır.

1.3. Araştırma Soruları ve Hipotezler

Bu çalışma kapsamında makine öğrenmesi modellerinde doğruluk ve adalet arasındaki ilişkinin incelenmesi amacıyla aşağıdaki araştırma soruları oluşturulmuştur:

Araştırma Soruları

AS1: Farklı makine öğrenmesi modelleri doğruluk ve adalet açısından nasıl performans göstermektedir?

AS2: Korunan özniteliklerin veri setinden çıkarılması algoritmik yanlılığı azaltmak için yeterli midir?

AS3: Fairness-aware yöntemler (Reweighing ve Exponentiated Gradient) adalet metriklerinde ne ölçüde iyileşme sağlamaktadır?

AS4: Doğruluk ve adalet arasında nasıl bir ödünleşim bulunmaktadır?

Bu araştırma sorularını değerlendirmek amacıyla aşağıdaki hipotezler oluşturulmuştur.

Hipotezler

H1: XGBoost ve Random Forest gibi topluluk (ensemble) öğrenme modelleri, Logistic Regression ve Decision Tree modellerine göre daha yüksek doğruluk ve ROC-AUC performansı sağlayacaktır.

Bu hipotez, ensemble yöntemlerin karmaşık örüntüleri daha başarılı öğrenebilmesi nedeniyle oluşturulmuştur.

H2: Reweighing ve Exponentiated Gradient gibi fairness-aware yöntemler, Statistical Parity Difference (SPD) ve Equal Opportunity Difference (EOD) gibi adalet metriklerinde iyileşme sağlarken belirli ölçüde performans kaybına neden olacaktır.

Bu hipotez, doğruluk ve adalet hedeflerinin çoğu zaman birbiriyle rekabet eden optimizasyon amaçları olmasına dayanmaktadır.

H3: Korunan özniteliklerin (sex) veya demografik değişkenlerin veri setinden çıkarılması tek başına algoritmik adaleti sağlamak için yeterli olmayacaktır.

Bu hipotez, korunan özniteliklerle ilişkili vekil değişkenlerin (proxy attributes) model tarafından kullanılmaya devam edebileceği varsayımına dayanmaktadır.

H4: Pareto Frontier analizi sonucunda doğruluk ve adalet arasında doğal bir ödünleşim bulunduğu gözlenecektir.

Bu hipotez, adalet iyileştirme yöntemlerinin grup temelli ayrımcılığı azaltırken model performansında belirli ölçüde kayba neden olabileceği varsayımına dayanmaktadır.

2. KAVRAMSAL ÇERÇEVE

2.1 Algoritmik Yanlılık ve Algoritmik Adalet

Algoritmik yanlılık, bir makine öğrenmesi sisteminin belirli bireyler veya gruplar üzerinde sistematik olarak avantajlı ya da dezavantajlı sonuçlar üretmesi olarak tanımlanmaktadır. Bu durum çoğu zaman eğitim verilerinde bulunan tarihsel eşitsizliklerin, temsil dengesizliklerinin veya toplumsal önyargıların model tarafından öğrenilmesi sonucunda ortaya çıkmaktadır (Caton & Haas, 2024).

Makine öğrenmesi modelleri eğitim verilerindeki örüntüleri öğrenirken yalnızca hedef değişken ile ilişkili bilgileri değil, aynı zamanda veri içerisindeki önyargılı ilişkileri de öğrenebilmektedir. Bu nedenle yüksek doğruluk elde eden bir model, belirli gruplar için sistematik olarak farklı kararlar üretebilir. Özellikle işe alım, kredi değerlendirme, sağlık hizmetleri ve kamu politikaları gibi yüksek riskli alanlarda bu durum önemli etik ve hukuki sorunlara yol açabilmektedir.

Literatürde algoritmik adalet, farklı demografik grupların karar süreçlerinden eşit veya kabul edilebilir düzeyde faydalanmasını amaçlayan bir yaklaşım olarak tanımlanmaktadır. Bu kapsamda çeşitli grup adaleti ve bireysel adalet tanımları geliştirilmiş olup, günümüzde en yaygın kullanılan yöntemler grup temelli adalet metriklerine dayanmaktadır (Hardt et al., 2016).

Algoritmik yanlılığın azaltılmasına yönelik ilk yaklaşımlardan biri korunan özniteliklerin veri setinden çıkarılmasıdır. Ancak son yıllarda yapılan çalışmalar, bu yaklaşımın çoğu durumda yeterli olmadığını göstermektedir. Çünkü eğitim düzeyi, meslek, gelir veya çalışma süresi gibi değişkenler korunan özniteliklerle yüksek korelasyona sahip olabilir ve model tarafından vekil değişken (proxy attribute) olarak kullanılabilir. Bu durum literatürde proxy discrimination olarak adlandırılmaktadır (Caton & Haas, 2024).

Bu çalışmada da benzer bir durum gözlenmiş ve cinsiyet değişkeninin veri setinden çıkarılmasının tek başına adalet metriklerinde anlamlı bir iyileşme sağlamadığı görülmüştür. Bu nedenle algoritmik adaletin yalnızca hassas değişkenlerin kaldırılmasıyla değil, fairness-aware yöntemlerin kullanılmasıyla daha etkili biçimde iyileştirilebileceği değerlendirilmektedir.

2.2 Adalet Değerlendirme Metrikleri

Makine öğrenmesi modellerinin adalet açısından değerlendirilmesinde çok sayıda metrik geliştirilmiştir. Bu çalışmada literatürde yaygın olarak kullanılan Statistical Parity Difference (SPD), Equal Opportunity Difference (EOD) ve Disparate Impact (DI) metrikleri kullanılmıştır.

2.2.1 Statistical Parity Difference (SPD)

Statistical Parity Difference (SPD), farklı grupların pozitif karar alma oranları arasındaki farkı ölçmektedir. SPD aşağıdaki şekilde tanımlanmaktadır:

$$SPD = P(\hat{Y}=1 \mid A=\text{korunan grup}) - P(\hat{Y}=1 \mid A=\text{referans grup})$$

Burada $\hat{Y}$ model tahminini, A ise hassas özelliği temsil etmektedir. SPD değerinin sıfıra yaklaşması gruplar arasında daha dengeli karar dağılımına işaret etmektedir. Pozitif veya negatif yönde büyük değerler ise belirli grupların avantajlı veya dezavantajlı konuma düştüğünü göstermektedir (Kamiran & Calders, 2012).

Bu çalışmada SPD, kadın ve erkek grupları arasındaki pozitif gelir tahmin oranlarının karşılaştırılmasında kullanılmıştır.

2.2.2 Equal Opportunity Difference (EOD)

Equal Opportunity Difference (EOD), farklı gruplar arasındaki True Positive Rate (TPR) farkını ölçmektedir. Bu metrik özellikle olumlu sonuçların eşit dağıtılıp dağıtılmadığını değerlendirmek amacıyla kullanılmaktadır.

EOD aşağıdaki şekilde hesaplanmaktadır:

$$EOD = TPR(\text{korunan grup}) - TPR(\text{referans grup})$$

EOD değerinin sıfıra yakın olması, pozitif örneklerin her iki grup için benzer oranlarda doğru sınıflandırıldığını göstermektedir. Büyük farklar ise modelin bir grup için diğerine kıyasla daha avantajlı sonuçlar ürettiğini ifade etmektedir (Hardt et al., 2016).

2.2.3 Disparate Impact (DI)

Disparate Impact (DI), korunan ve korunmayan grupların pozitif karar alma oranlarının oranını ifade etmektedir.

DI aşağıdaki şekilde hesaplanmaktadır:

$$DI = P(\hat{Y}=1 \mid \text{Korunan Grup}) / P(\hat{Y}=1 \mid \text{Referans Grup})$$

DI değerinin 1'e yaklaşması daha dengeli karar dağılımını göstermektedir. Literatürde yaygın olarak kullanılan “80% Rule” yaklaşımına göre DI değerinin 0.80'in altında olması potansiyel ayrımcılık göstergesi olarak değerlendirilmektedir (Kamiran & Calders, 2012)

Bu çalışmada SPD ve EOD metriklerine ek olarak DI metriği de kullanılarak modellerin grup adaleti açısından daha kapsamlı biçimde değerlendirilmesi amaçlanmıştır.

2.3 Doğruluk–Adalet Ödünleşimi (Accuracy–Fairness Trade-Off)

Makine öğrenmesi sistemlerinde doğruluk ve adalet çoğu zaman birbiriyle rekabet eden iki optimizasyon hedefi olarak ortaya çıkmaktadır. Bir modelin doğruluğunu artırmak amacıyla geliştirilen yöntemler bazı durumlarda belirli gruplar arasındaki eşitsizlikleri artırabilmekte, buna karşılık adaleti artırmaya yönelik müdahaleler ise model performansında belirli ölçüde kayba neden olabilmektedir (Chouldechova, 2017).

Bu durum literatürde doğruluk–adalet ödünleşimi (accuracy–fairness trade-off) olarak adlandırılmaktadır. Özellikle grup temelli adalet kısıtlarının uygulandığı modellerde farklı gruplar arasındaki karar oranlarının dengelenmesi amaçlanırken, modelin genel tahmin başarısında belirli düzeyde düşüş gözlemlenmektedir (Plečko & Bareinboim, 2024).

Adalet iyileştirme yöntemleri genel olarak üç ana grupta incelenmektedir:

1. Ön işleme (Pre-processing) yöntemleri
2. Öğrenme süreci (In-processing) yöntemleri
3. Son işleme (Post-processing) yöntemleri

Bu çalışmada ön işleme yaklaşımı olarak Reweighing yöntemi, öğrenme sürecine müdahale eden yöntem olarak ise Exponentiated Gradient yaklaşımı kullanılmıştır. Her iki yöntemin doğruluk ve adalet üzerindeki etkileri deneysel olarak değerlendirilmiştir.

Doğruluk ve adalet arasındaki ilişkinin daha kapsamlı incelenebilmesi amacıyla bu çalışmada Accuracy–SPD trade-off analizi kullanılmıştır. Accuracy–SPD trade-off analizi sayesinde modellerin doğruluk ve adalet açısından göreceli konumları görselleştirilmiş ve farklı yöntemlerin sunduğu ödünleşimler karşılaştırılmıştır. Böylece yalnızca en yüksek doğruluğa sahip model değil, doğruluk ve adalet arasında en dengeli çözümü sunan modeller de belirlenebilmiştir.

3. MATERYAL VE YÖNTEM

Bu bölümde çalışmada kullanılan veri seti, uygulanan veri ön işleme adımları, kullanılan makine öğrenmesi modelleri, adalet değerlendirme metrikleri ve fairness-aware müdahale yöntemleri açıklanmaktadır.

3.1 Veri Seti

Bu çalışmada algoritmik adalet analizlerinde yaygın olarak kullanılan Adult Census Income veri seti kullanılmıştır. Veri seti ilk olarak 1994 yılında ABD Nüfus Sayımı (U.S. Census Bureau) verilerinden oluşturulmuş olup bireylerin yıllık gelir düzeyinin 50.000 doların üzerinde olup olmadığını tahmin etmeyi amaçlamaktadır. Veri seti yaş, eğitim düzeyi, çalışma süresi, medeni durum, meslek, sermaye kazancı ve demografik bilgiler gibi çeşitli sosyo-ekonomik özellikleri içermektedir.

Adult veri seti, farklı demografik gruplar arasındaki gelir dağılımı farklılıklarını içermesi nedeniyle algoritmik adalet çalışmalarında sıklıkla tercih edilmektedir. Bununla birlikte veri seti tarihsel eşitsizlikleri ve grup dengesizliklerini yansıtmaması nedeniyle fairness araştırmaları açısından önemli bir benchmark olarak kabul edilmektedir (Ding et al., 2021).

Veri ön işleme sonrasında elde edilen veri setinin genel özellikleri Tablo 1’de verilmiştir.

Tablo 1 Veri Seti Özeti

Özellik	Değer
Ham veri sayısı	32,561
Temiz veri sayısı	30,162
Erkek birey sayısı	20,380
Kadın birey sayısı	9,782
Gelir $\leq$ 50K	22,654
Gelir $>$ 50K	7,508

Bu çalışmada korunan öznitelik (protected attribute) olarak cinsiyet (sex) değişkeni kullanılmıştır. Adalet analizleri kadın ve erkek grupları arasındaki karar farklılıkları üzerinden gerçekleştirilmiştir.

3.2 Veri Ön İşleme Süreci

Makine öğrenmesi modellerinin eğitilmesinden önce veri setine çeşitli ön işleme adımları uygulanmıştır.


İlk aşamada eksik veya bilinmeyen değerler veri setinden temizlenmiştir. Adult veri setinde bazı kategorik değişkenlerde yer alan "?" değerleri eksik veri olarak değerlendirilmiş ve veri temizleme sürecine dahil edilmiştir.

Daha sonra hedef değişken olan income sütunu ikili sınıflandırma problemine dönüştürülmüştür. Geliri 50.000 doların altında veya eşit olan bireyler 0, geliri 50.000 doların üzerinde olan bireyler ise 1 olarak kodlanmıştır.

Kategorik değişkenler makine öğrenmesi algoritmaları tarafından kullanılabilir hale getirilmek amacıyla One-Hot Encoding yöntemi ile sayısal formata dönüştürülmüştür. Sayısal değişkenler ise StandardScaler yöntemi kullanılarak standartlaştırılmıştır.

Veri seti eğitim ve test kümelerine ayrılmıştır. Çalışmada %80 eğitim ve %20 test oranı kullanılmıştır. Eğitim ve test kümeleri oluşturulurken hedef değişken dağılımının korunması amacıyla stratified sampling yaklaşımı uygulanmıştır.

Ön işleme sürecinin genel akışı Şekil 1’de gösterilmektedir.



Şekil 1 Veri İşleme ve Deney Akışı

3.3 Kullanılan Makine Öğrenmesi Modelleri

Çalışmada farklı öğrenme yaklaşımlarını temsil eden dört temel sınıflandırma algoritması kullanılmıştır.

3.3.1 Logistic Regression

Logistic Regression doğrusal karar sınırları oluşturan ve yorumlanabilirliği yüksek bir sınıflandırma algoritmasıdır. Özellikle fairness çalışmalarında temel karşılaştırma modeli olarak yaygın biçimde kullanılmaktadır.(Saha, 2025).

3.3.2 Decision Tree

Decision Tree algoritması karar süreçlerini ağaç yapısı şeklinde modelleyen ve yorumlanabilir sonuçlar üreten bir yöntemdir. Model karar mekanizmasının kolay açıklanabilmesi nedeniyle çalışmaya dahil edilmiştir.

3.3.3 Random Forest

Random Forest çok sayıda karar ağacının birleşiminden oluşan bir ensemble öğrenme yöntemidir. Rastgele örnekleme ve özellik seçimi kullanarak daha kararlı ve genellenebilir sonuçlar üretmektedir.

3.3.4 XGBoost

XGBoost günümüzde en başarılı gradient boosting algoritmalarından biri olarak kabul edilmektedir. Karmaşık veri örüntülerini öğrenebilme kapasitesi ve yüksek performansı nedeniyle çalışmaya dahil edilmiştir.

3.4 DeneySEL Tasarım

Çalışma beş temel deney aşamasından oluşmaktadır.

Baseline Deneyi

İlk aşamada tüm özellikler kullanılarak Logistic Regression, Decision Tree, Random Forest ve XGBoost modelleri eğitilmiştir. Bu deney referans sonuçların elde edilmesi amacıyla gerçekleştirilmiştir.

No-Sex Deneyi

Bu deneyde sex değişkeni veri setinden çıkarılmış ve modeller yeniden eğitilmiştir. Amaç korunan özniteliğin kaldırılmasının adalet üzerindeki etkisini incelemektir.

No-Demographic Deneyi

Bu aşamada sex, race, native-country, marital-status ve relationship değişkenleri veri setinden çıkarılmıştır. Böylece demografik bilgilerin model davranışına etkisi değerlendirilmiştir.

Reweighting Deneyi

Veri ön işleme aşamasında kullanılan Reweighting yöntemi ile farklı grup ve sınıf kombinasyonlarına ağırlıklar atanmıştır. Bu sayede eğitim verisindeki grup dengesizliklerinin etkisinin azaltılması amaçlanmıştır (Kamiran & Calders, 2012).

Exponentiated Gradient Deneyi

In-processing yaklaşımı olarak Exponentiated Gradient yöntemi uygulanmıştır. Bu yöntem eğitim sürecine doğrudan adalet kısıtları ekleyerek grup temelli ayrımcılığı azaltmayı hedeflemektedir (Agarwal et al., 2018).

3.5 Değerlendirme Metrikleri

Modellerin performans değerlendirmesinde Accuracy, Precision, Recall, F1-Score ve ROC-AUC metrikleri kullanılmıştır.

Adalet değerlendirmesinde ise Statistical Parity Difference (SPD), Equal Opportunity Difference (EOD) ve Disparate Impact (DI) metrikleri hesaplanmıştır.

Son olarak doğruluk ve adalet arasındaki ilişkiyi değerlendirmek amacıyla Accuracy–SPD trade-off analizi gerçekleştirilmiştir.

Sonuçların farklı veri bölünmelerine karşı kararlılığını değerlendirmek amacıyla ek olarak 5-Fold Stratified Cross Validation uygulanmıştır. Bu analizde veri seti beş alt kümeye ayrılmış, her iterasyonda bir alt küme test verisi olarak kullanılmıştır. Böylece elde edilen performans ve adalet metriklerinin yalnızca belirli bir train-test ayırımına bağlı olup olmadığı değerlendirilmiştir. Sonuçlar ortalama (mean) ve standart sapma (standard deviation) değerleri ile raporlanmıştır.

4.BULGULAR VE DEĞERLENDİRME

Bu bölümde gerçekleştirilen deneylerden elde edilen sonuçlar performans ve adalet metrikleri açısından değerlendirilmiştir. İlk olarak temel modellerin sonuçları incelenmiş, ardından korunan özniteliklerin kaldırılmasının etkileri analiz edilmiş ve son olarak fairness-aware yöntemlerin performansı değerlendirilmiştir.

4.1 Baseline Model Sonuçları

Çalışmanın ilk aşamasında Logistic Regression, Decision Tree, Random Forest ve XGBoost modelleri tüm özellikler kullanılarak eğitilmiş ve performansları karşılaştırılmıştır.

Tablo 2 Baseline Modellerin Sonuçları

Model	Accuracy	Precision	Recall	F1	ROC-AUC	SPD	EOD	DI
Logistic Regression	0.8589	0.7594	0.6345	0.6913	0.9180	0.1755	0.0732	0.3356
Decision Tree	0.8155	0.6312	0.6232	0.6271	0.7512	0.1815	0.0894	0.4026
Random Forest	0.8560	0.7448	0.6411	0.6891	0.9083	0.1832	0.0811	0.3286
XGBoost	0.8752	0.8008	0.6638	0.7259	0.9358	0.1715	0.0600	0.3433

Tablo 2 incelendiğinde XGBoost modelinin doğruluk, F1-Skoru ve ROC-AUC açısından en başarılı model olduğu görülmektedir. Ancak yüksek performans değerlerine rağmen tüm modellerin SPD ve DI metrikleri açısından belirli düzeyde grup farklılıkları ürettiği gözlenmiştir.Yüksek doğruluk elde edilmesinin tek başına adil kararlar üretildiği anlamına gelmediğini göstermektedir.

4.1.1 K-Fold Çapraz Doğrulama Sonuçları

Tablo 3 XGBoost K-Fold Çapraz Doğrulama Sonuçları

Model	Accuracy	F1	ROC-AUC
XGBoost (5-Fold)	0.8705 $\pm$ 0.0025	0.7186 $\pm$ 0.0052	0.9279 $\pm$ 0.0030

Elde edilen sonuçların belirli bir train-test ayrımından kaynaklanmadığını doğrulamak amacıyla XGBoost modeli üzerinde 5-Fold Stratified Cross Validation uygulanmıştır. Sonuçlar incelendiğinde ortalama doğruluk değerinin 0.8705 ± 0.0025 , ortalama F1-skorunun 0.7186 ± 0.0052 ve ortalama ROC-AUC değerinin 0.9279 ± 0.0030 olduğu görülmektedir. Düşük standart sapma değerleri, model performansının farklı veri bölünmelerinde kararlı olduğunu ve elde edilen sonuçların tesadüfi bir veri ayrımından kaynaklanmadığını göstermektedir.

4.2 Korunan Özniteliklerin Kaldırılmasının Etkisi

Korunan özniteliklerin veri setinden çıkarılmasının adalet üzerindeki etkisini değerlendirmek amacıyla No-Sex ve No-Demographic deneyleri gerçekleştirilmiştir.

Tablo 4 No-Sex Deneyi Sonuçları

Model	Accuracy	SPD	EOD	DI
LogisticRegression_NoSex	0.8588	0.1702	0.0632	0.3476
DecisionTree_NoSex	0.8130	0.1732	0.0822	0.4310
RandomForest_NoSex	0.8561	0.1764	0.0694	0.3584
XGBoost_NoSex	0.8740	0.1682	0.0569	0.3529

No-Sex deneyinde sex değişkeninin veri setinden çıkarılmasına rağmen adalet metriklerinde yalnızca sınırlı değişiklikler gözlenmiştir. Özellikle XGBoost modelinde SPD değeri 0.1715'ten 0.1682'ye düşmüş olup bu değişim oldukça sınırlıdır. Benzer şekilde diğer modellerde de önemli bir iyileşme elde edilmemiştir.

Bu sonuç, korunan özneliğin kaldırılmasının tek başına algoritmik adaleti sağlamadığını göstermektedir.

Tablo 5 No-Demographic Deneyi Sonuçları

Model	Accuracy	SPD	EOD	DI
LogisticRegression_NoDemo	0.8596	0.1917	0.1500	0.2774
DecisionTree_NoDemo	0.8182	0.1846	0.0877	0.4086
RandomForest_NoDemo	0.8548	0.1885	0.0924	0.3173
XGBoost_NoDemo	0.8773	0.1823	0.1174	0.3045

No-Demographic deneyinde demografik değişkenlerin çıkarılması da beklenen adalet iyileşmesini sağlamamıştır. Bazı modellerde SPD değerinin arttığı gözlenmiştir. Bu sonuç, veri setindeki önyargının yalnızca açık demografik değişkenlerden değil, eğitim düzeyi, çalışma süresi, meslek ve sermaye kazancı gibi değişkenler üzerinden de taşınabildiğini göstermektedir.

4.3 Fairness Müdahalelerinin Etkisi

Bu aşamada Reweighing ve Exponentiated Gradient yöntemleri uygulanarak modellerin adalet performansları değerlendirilmiştir.

Tablo 6 Reweighing Sonuçları

Model	Accuracy	F1	ROC-AUC	SPD	EOD	DI
LogisticRegression_Reweighing	0.8493	0.6604	0.9105	0.0821	0.1657	0.6286
RandomForest_Reweighing	0.8555	0.6901	0.9092	0.1833	0.0767	0.3361
XGBoost_Reweighing	0.8707	0.7098	0.9314	0.0893	0.1586	0.6033

Reweighing yöntemi özellikle Logistic Regression ve XGBoost modellerinde SPD ve DI açısından önemli iyileşmeler sağlamıştır. XGBoost modelinde SPD değeri yaklaşık %48 oranında azalmış, buna karşılık doğrulukta yalnızca sınırlı bir düşüş meydana gelmiştir.

Tablo 7 K-Fold Fairness Sonuçları

Model	Accuracy	SPD	EOD	DI
XGBoost	0.8705 $\pm$ 0.0025	0.1890 $\pm$ 0.0075	0.0998 $\pm$ 0.0262	0.3070 $\pm$ 0.0249
XGBoost + Reweighing	0.8649 $\pm$ 0.0042	0.1074 $\pm$ 0.0128	0.1185 $\pm$ 0.0309	0.5391 $\pm$ 0.0462

Reweighing yönteminin etkisinin yalnızca belirli bir train-test ayırımına bağlı olup olmadığını değerlendirmek amacıyla 5-Fold Stratified Cross Validation uygulanmıştır. Sonuçlar, Reweighing yönteminin farklı veri bölünmelerinde de benzer davranış sergilediğini göstermektedir. SPD değeri ortalama 0.1890'dan 0.1074'e düşerken DI değeri 0.3070'dan 0.5391'e yükselmiştir. Buna karşılık doğruluk değeri yalnızca 0.8705'ten 0.8649'a gerilemiştir. Bu bulgu, Reweighing yönteminin performans kaybını sınırlı tutarken adalet metriklerinde tutarlı iyileşmeler sağlayabildiğini göstermektedir.

Tablo 8 Exponentiated Gradient Sonuçları


Model	Accuracy	F1	ROC-AUC	SPD	EOD	DI
LogisticRegression_ExpGrad	0.8409	0.6273	0.7450	0.0133	0.3096	0.9272

ExpGrad yöntemi çalışmadaki en düşük SPD ve en yüksek DI değerlerini elde ederek grup adaleti açısından en başarılı sonuçları üretmiştir. Bununla birlikte doğruluk performansında belirli ölçüde azalma meydana gelmiştir. Bu durum fairness-aware yöntemlerin performans maliyeti oluşturabileceğini göstermektedir.

4.4 Doğruluk–Adalet Ödünleşimi Analizi

Doğruluk ve adalet arasındaki ilişkiyi daha anlaşılır biçimde değerlendirmek amacıyla Accuracy–SPD (Statistical Parity Difference) ödünleşim analizi gerçekleştirilmiştir. Bu analizde yatay eksen model doğruluğunu (Accuracy), dikey eksen ise mutlak SPD değerini göstermektedir. Daha yüksek doğruluk değerleri daha başarılı sınıflandırma performansını temsil ederken, daha düşük SPD değerleri gruplar arasındaki karar farklılıklarının azaldığını ve

dolayısıyla daha adil sonuçlar elde edildiğini göstermektedir. Bu nedenle ideal modeller grafiğin sağ alt bölgesinde konumlanmaktadır.



Şekil 2 Accuracy-SPD Doğruluk-Adalet Ödünleşimi Grafiği

Şekil 2 incelendiğinde XGBoost modelinin en yüksek doğruluk değerlerinden birini elde ettiği görülmektedir. Ancak bu model görece yüksek SPD değerleri üreterek kadın ve erkek grupları arasında belirgin karar farklılıkları oluşturmuştur. Benzer şekilde No-Sex ve No-Demographic deneyleri de korunan öznelitliklerin veri setinden çıkarılmasının tek başına adaleti sağlamada yeterli olmadığını göstermiştir.

Buna karşılık XGBoost + Reweighing modeli doğruluk performansını büyük ölçüde korurken SPD değerini önemli ölçüde azaltmıştır. Özellikle 5-Fold Stratified Cross Validation sonuçlarında SPD değerinin ortalama **0.1890'dan 0.1074'e** düştüğü ve Disparate Impact değerinin **0.3070'dan 0.5391'e** yükseldiği gözlenmiştir. Bu sonuçlar Reweighing yönteminin farklı veri bölünmelerinde de tutarlı biçimde adalet iyileştirmesi sağlayabildiğini göstermektedir.

Logistic Regression + ExpGrad modeli ise en düşük SPD değerini elde ederek en adil model olarak öne çıkmıştır. Bununla birlikte doğruluk performansında belirli bir azalma meydana gelmiştir. Bu durum, doğruluk ve adalet arasında doğal bir ödünleşim bulunduğunu ve adalet kısıtlarının uygulanmasının belirli bir performans maliyeti oluşturabileceğini göstermektedir.

Genel olarak deęerlendirildięinde sonular, yksek doęruluk saęlayan modellerin her zaman en adil modeller olmadıęını ortaya koymaktadır. Fairness-aware yntemler belirli dzeyde performans kaybı karřılıęında grup temelli ayrımcılıęı azaltabilmekte ve daha dengeli karar mekanizmaları oluřturabilmektedir. alıřma kapsamında XGBoost + Reweighing modeli doęruluk ve adalet arasında en uygun dengeyi saęlayan yaklařım olarak ne ıkmıřtır.

5.TARTIřMA.

5.1. Korunan zniteliklerin Kaldırılmasının Etkisi

Bu alıřmada algoritmik nyargının yalnızca korunan zniteliklerden kaynaklanıp kaynaklanmadıęını incelemek amacıyla No-Sex ve No-Demographic deneyleri gerekleřtirilmiřtir. No-Sex deneyinde cinsiyet deęiřkeni veri setinden ıkarılmıř, No-Demographic deneyinde ise sex, race, native-country, marital-status ve relationship gibi demografik veya demografik zelliklerle gl iliřkiye sahip deęiřkenler veri setinden kaldırılmıřtır.

Elde edilen sonular, korunan zniteliklerin veri setinden ıkarılmasının adalet metriklerinde anlamlı bir iyileřme saęlamadıęını gstermiřtir. rneęin XGBoost modelinde SPD deęeri baseline senaryosunda 0.1715 iken, No-Sex deneyinde yalnızca 0.1682 seviyesine dřmřtr. Benzer řekilde No-Demographic deneyinde bazı modellerde SPD deęerinin arttıęı gzlenmiřtir. Bu sonular, yalnızca korunan znitelięin kaldırılmasının algoritmik adaleti saęlamak iin yeterli olmadıęını gstermektedir.

Bu durum literatrde "proxy discrimination" olarak adlandırılan olguyla aıklanabilir.(Caton & Haas, 2024) Model doęrudan cinsiyet bilgisini kullanmasa bile eęitim dzeyi, meslek, alıřma sresi ve sermaye kazancı gibi deęiřkenler zerinden benzer rntleri ęrenebilmektedir. Dolayısıyla veri setindeki tarihsel ve yapısal eřitsizlikler, korunan znitelikler kaldırılmıř olsa dahi model kararlarına yansımaya devam etmektedir. Bu bulgu, fairness through unawareness yaklařımının tek bařına yeterli olmadıęını gsteren alıřmalarla uyumludur.

5.2. Fairness Mdahalelerinin Karřılařtırılması

alıřmada veri n iřleme temelli Reweighing yntemi ile ęrenme srecine doęrudan mdahale eden Exponentiated Gradient (ExpGrad) yntemi karřılařtırılmıřtır. Her iki yntemin

de adalet metriklerinde iyileşme sağladığı görülmekle birlikte, performans ve adalet arasındaki denge açısından farklı davranışlar sergiledikleri gözlenmiştir.

Reweighing yöntemi özellikle XGBoost modelinde başarılı sonuçlar vermiştir. XGBoost modelinde SPD değeri 0.1715'ten 0.0893'e düşerken doğruluk değeri yalnızca 0.8752'den 0.8707'ye gerilemiştir. Bu durum, Reweighing yönteminin performans kaybını sınırlı tutarak grup temelli ayrımcılığı azaltabildiğini göstermektedir. Benzer şekilde DI değerinin 0.3433'ten 0.6033'e yükselmesi de yöntemin adalet açısından olumlu katkısını ortaya koymaktadır.

ExpGrad yöntemi ise çalışmadaki en yüksek adalet performansını üretmiştir. Logistic Regression tabanlı ExpGrad modeli SPD değerini 0.0133 seviyesine kadar düşürmüş ve DI değerini 0.9272 seviyesine yükseltmiştir. Bu sonuçlar, modelin kadın ve erkek grupları arasında neredeyse eşit karar dağılımı oluşturduğunu göstermektedir. Ancak bu iyileşme doğruluk değerinin 0.8409 seviyesine düşmesiyle elde edilmiştir.

Sonuç olarak Reweighing yöntemi doğruluk ve adalet arasında daha dengeli bir çözüm sunarken, ExpGrad yöntemi maksimum adalet hedefleyen ancak belirli ölçüde performans kaybına neden olan bir yaklaşım olarak öne çıkmıştır.

5.3. Doğruluk–Adalet Ödünleşimi

Makine öğrenmesi sistemlerinde doğruluk ve adalet hedefleri çoğu zaman birbiriyle rekabet eden iki optimizasyon amacı olarak ortaya çıkmaktadır. Bu nedenle çalışmada modeller arasındaki dengeyi incelemek amacıyla Accuracy–SPD trade-off analizi gerçekleştirilmiştir.

Accuracy–SPD trade-off analizi sonuçları incelendiğinde, en yüksek doğruluk değerlerinin XGBoost tabanlı modeller tarafından elde edildiği görülmüştür. Özellikle XGBoost ve XGBoost_NoDemographic modelleri %87'nin üzerinde doğruluk sağlayarak en başarılı tahmin performansını göstermiştir. Ancak bu modeller aynı zamanda görece yüksek SPD değerlerine sahip olmuş ve grup temelli ayrımcılığı tam olarak ortadan kaldıramamıştır.

Buna karşılık Logistic Regression + ExpGrad modeli en düşük SPD ve en yüksek DI değerlerini elde ederek çalışmanın en adil modeli olmuştur. Ancak bu modelde doğruluk performansında

belirli bir azalma meydana gelmiştir. Bu durum, algoritmik adalet çalışmalarında sıklıkla vurgulanan doğruluk–adalet ödünleşimini açık biçimde göstermektedir.

Accuracy–SPD trade-off analizi kapsamında, XGBoost + Reweighing modeli yüksek doğruluğu korurken önemli ölçüde adalet iyileşmesi sağlaması nedeniyle en dengeli çözümlerden biri olarak öne çıkmaktadır. Logistic Regression + ExpGrad modeli ise maksimum adalet hedeflenen senaryolarda tercih edilebilecek bir alternatif olarak değerlendirilebilir.

Genel olarak çalışma sonuçları, tek bir modelin hem maksimum doğruluk hem de maksimum adaleti aynı anda sağlayamadığını göstermektedir. Bu nedenle gerçek dünya uygulamalarında kullanılacak modelin seçiminde yalnızca performans metriklerinin değil, adalet metriklerinin de dikkate alınması gerekmektedir.

5.4. Çalışmanın Kısıtları

Bu çalışmada yalnızca Adult Census Income veri seti kullanılmıştır. Veri setinin tarihsel olarak 1994 ABD nüfus sayımı verilerine dayanması, elde edilen bulguların günümüz sosyo-ekonomik koşullarına doğrudan genellenmesini sınırlandırabilir. Ayrıca fairness analizleri yalnızca cinsiyet değişkeni üzerinden gerçekleştirilmiştir. Farklı korunan öznitelikler veya çoklu korunan grup kombinasyonları kullanıldığında farklı sonuçlar elde edilebilir. Son olarak ExpGrad yöntemi yalnızca Logistic Regression modeli üzerinde uygulanmış olup diğer modeller için fairness-aware optimizasyon stratejileri değerlendirilmemiştir.

6.SONUÇ VE ÖNERİLER

6.1. Çalışmanın Temel Sonuçları

Bu çalışmada Adult Census Income veri seti kullanılarak makine öğrenmesi modellerinde doğruluk ve adalet arasındaki ilişki incelenmiştir. Çalışma kapsamında Logistic Regression, Decision Tree, Random Forest ve XGBoost modelleri değerlendirilmiş; ayrıca Reweighing ve Exponentiated Gradient gibi fairness-aware yöntemlerin model performansı üzerindeki etkileri analiz edilmiştir.

Elde edilen sonuçlar, XGBoost modelinin doğruluk, F1-skoru ve ROC-AUC açısından en başarılı temel model olduğunu göstermiştir. Bununla birlikte yüksek performanslı

modellerin grup temelli ayrımcılığı tamamen ortadan kaldıramadığı ve belirli ölçüde önyargı üretebildiği gözlemlenmiştir. Bu durum, yüksek tahmin başarısının tek başına güvenilir ve adil kararlar üretmek için yeterli olmadığını göstermektedir.

Çalışmanın önemli bulgularından biri, korunan özniteliklerin veri setinden çıkarılmasının adalet açısından anlamlı bir iyileşme sağlamamış olmasıdır. No-Sex ve No-Demographic deneylerinde elde edilen sonuçlar, cinsiyet veya diğer demografik değişkenlerin kaldırılmasının algoritmik önyargıyı ortadan kaldırmak için yeterli olmadığını ortaya koymuştur. Bu durum veri setindeki örtük ilişkilerin ve vekil değişkenlerin karar mekanizmasını etkilemeye devam ettiğini göstermektedir.

Fairness müdahaleleri değerlendirildiğinde, Reweighing yönteminin doğruluk ve adalet arasında dengeli bir çözüm sunduğu görülmüştür. Özellikle XGBoost + Reweighing modeli yüksek doğruluğu büyük ölçüde korurken adalet metriklerinde belirgin iyileşme sağlamıştır. Buna karşılık Exponentiated Gradient yöntemi en yüksek adalet performansını üretmiş, ancak belirli ölçüde doğruluk kaybına neden olmuştur.

Accuracy–SPD trade-off analizi sonuçları doğruluk ve adalet arasında doğal bir ödünleşim bulunduğunu göstermiştir. En yüksek doğruluğu sağlayan modeller en adil modeller olmamış, en yüksek adalet performansını sağlayan modeller ise belirli ölçüde performans kaybı yaşamıştır. Bu sonuç, gerçek dünya uygulamalarında model seçiminde yalnızca performans metriklerinin değil adalet metriklerinin de dikkate alınması gerektiğini ortaya koymaktadır.

Sonuç olarak bu çalışma, algoritmik adalet probleminin yalnızca korunan özniteliklerin kaldırılmasıyla çözülemeyeceğini, fairness-aware yöntemlerin daha etkili sonuçlar üretebildiğini ve doğruluk ile adalet arasında dikkatle yönetilmesi gereken bir denge bulunduğunu göstermiştir

Ayrıca gerçekleştirilen 5-Fold Stratified Cross Validation analizleri, elde edilen sonuçların farklı veri bölünmelerinde de büyük ölçüde korunduğunu göstermiştir. Özellikle XGBoost ve XGBoost + Reweighing modelleri düşük standart sapma değerleri sergileyerek performans ve adalet sonuçlarının kararlı olduğunu ortaya koymuştur. Bu durum, çalışmada elde edilen bulguların yalnızca tek bir train-test ayırımına bağlı olmadığını desteklemektedir.

Çalışmanın sonuçları, algoritmik adalet probleminin yalnızca teknik bir optimizasyon problemi olmadığını; aynı zamanda etik, sosyal ve yönetsel boyutları bulunan çok disiplinli bir araştırma alanı olduğunu göstermektedir.

Bu çalışma sonucunda en yüksek performans XGBoost modeli tarafından elde edilirken, doğruluk ve adalet arasında en dengeli çözümün XGBoost + Reweighing kombinasyonu tarafından sağlandığı görülmüştür.

6.2. Gelecek Çalışmalar

Bu çalışmada algoritmik adalet değerlendirmeleri cinsiyet (sex) değişkeni üzerinden gerçekleştirilmiştir. Gelecek çalışmalarda ırk (race) gibi farklı korunan özniteliklerin de değerlendirilmesi, farklı gruplar arasındaki eşitsizliklerin daha kapsamlı biçimde incelenmesine katkı sağlayabilir.

Bunun yanında, yalnızca tek bir korunan öznitelik yerine birden fazla korunan özneliğin birlikte değerlendirildiği intersectional fairness analizleri gerçekleştirilebilir. Böylece belirli alt grupların karşılaştığı ayrımcılık daha ayrıntılı biçimde incelenebilir.

Çalışmada kullanılan fairness-aware yöntemler Reweighing ve Exponentiated Gradient ile sınırlı tutulmuştur. Gelecekte Equalized Odds, Threshold Optimizer, Adversarial Debiasing ve Reject Option Classification gibi farklı adalet iyileştirme yöntemlerinin de karşılaştırılması mümkündür.

Ayrıca SHAP ve benzeri açıklanabilir yapay zekâ yöntemleri kullanılarak modellerin karar süreçleri ayrıntılı biçimde analiz edilebilir. Bu sayede veri setindeki vekil değişkenlerin ve önyargı kaynaklarının daha açık biçimde ortaya konulması mümkün olacaktır.

Son olarak, bu çalışmada yaygın olarak kullanılan Adult Census Income veri seti tercih edilmiştir. Gelecek araştırmalarda sağlık, finans, işe alım ve kredi değerlendirme gibi yüksek riskli uygulama alanlarına ait veri setleri üzerinde benzer analizlerin gerçekleştirilmesi, elde edilen bulguların gerçek dünya senaryolarına genellenebilirliğini artıracaktır.

KAYNAKÇA

- Agarwal, A., Beygelzimer, A., Dudík, M., Langford, J., & Wallach, H. (2018). A reductions approach to fair classification. *Proceedings of the 35th International Conference on Machine Learning*, 80, 60–69
- .Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>
- Caton, S., & Haas, C. (2024). Fairness in Machine Learning: A Survey. *ACM Computing Surveys*, 56(7), 1–38. <https://doi.org/10.1145/3616865>
- Chouldechova, A. (2017). Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments. *Big Data*, 5(2), 153–163. <https://doi.org/10.1089/big.2016.0047>
- Ding, F., Hardt, M., Miller, J., & Schmidt, L. (2021). *Retiring Adult: New Datasets for Fair Machine Learning*. 6478–6490. <https://consensus.app/papers/retiring-adult-new-datasets-for-fair-machine-learning-ding-hardt/c8aec43204a5cd78674a5c187730ce2/>
- Gohar, U., Biswas, S., & Rajan, H. (2022). Towards Understanding Fairness and its Composition in Ensemble Machine Learning. *2023 IEEE/ACM 45th International Conference on Software Engineering (ICSE)*, 1533–1545. <https://doi.org/10.1109/icse48619.2023.00133>
- Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. *Advances in Neural Information Processing Systems*, 29.
- Hort, M., Chen, Z., Zhang, J. M., Harman, M., & Sarro, F. (2024). Bias Mitigation for Machine Learning Classifiers: A Comprehensive Survey. *ACM Journal on Responsible Computing*, 1(2), 1–52. <https://doi.org/10.1145/3631326>
- Kamiran, F., & Calders, T. (2012). Data preprocessing techniques for classification without discrimination. *Knowledge and Information Systems*, 33(1), 1–33. <https://doi.org/10.1007/s10115-011-0463-8>
- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). *A Survey on Bias and Fairness in Machine Learning*. <http://arxiv.org/abs/1908.09635>
- Plečko, D., & Bareinboim, E. (2024). *Fairness-Accuracy Trade-Offs: A Causal Perspective*. 26344–26353. <https://doi.org/10.48550/arxiv.2405.15443>
- Saha, S. K. (2025). A Comparative Analysis of Logistic Regression and Random Forest for Individual Fairness in Machine Learning. *International Journal of Advanced Engineering Research and Science*, 12(5), 33–37. <https://doi.org/10.22161/ijaers.125.5>